Linux 文件系统的演进

---

renyl 2015/5/20

目录

1 ext2 文件系统

1.1 文件系统的布局

我们知道，一个磁盘可以划分成多个分区，每个分区必须先用格式化工具（如 mkfs 命令）格式化成某种格式的文件系统，然后才能存储文件，格式化的过程中会在磁盘上写一些管理存储布局的信息。下图是一个磁盘分区格式化成 ext2 文件系统后的存储布局。

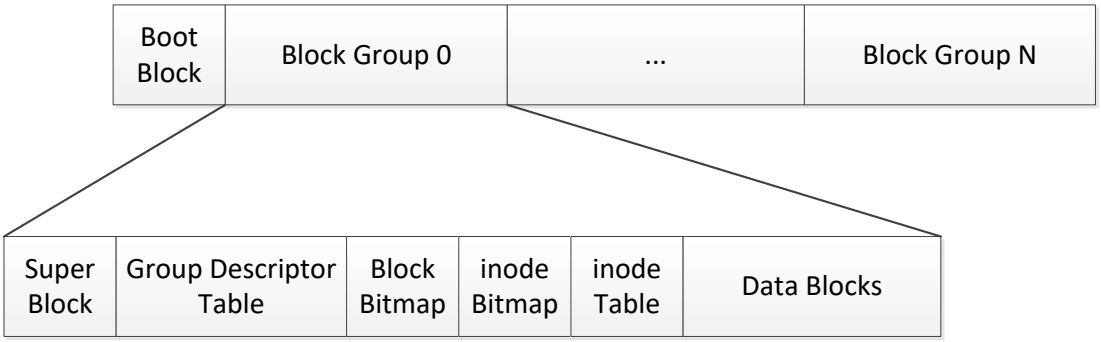

1.1.1 启动块（Boot Block）

启动块（Boot Block）是用来存储磁盘分区信息和启动信息，大小是固定的，为 1KB，任何文件系统都不能使用启动块。启动块之后才是 ext2 文件系统的开始，ext2 文件系统将整个分区划成若干个同样大小的块组（Block Group）。

1.1.2 超级块（Super Block）

1) 超级块描述整个分区的文件系统信息，如 inode 数、块数量、块大小、文件系统版本号、上次 mount 的时间等等。

2) 超级块在每个块组的开头都有一份拷贝，默认情况下，只有第一个块组的超级块会被系统内核使用，其他块组的超级块可以在 e2fsck 之类的程序对磁盘上的文件系统进行一致性检查时使用，这样当第一个块组的开头意外损坏时就可以使用其他拷贝来恢复，从而减少数据丢失。

3) 文件系统中存储的最小单位是块（Block），一个块究竟多大是在格式化时确定的（例如 mke2fs 的-b 选项可以设定块大小为 1024、2048 或 4096 字节）。超级块占用 1 个块大小。

4) 在 ext2 文件系统中，超级块通过一个名为 ext2_super_block 的结构进行描述，如下所示（引用自 Kernel 的/root/include/linux/ext2_fs.h）：

```
338 /*
339  * Structure of the super block
340  */
341 struct ext2_super_block {
342         __le32  s_inodes_count;         /* Inodes count */
343         __le32  s_blocks_count;         /* Blocks count */
344         __le32  s_r_blocks_count;       /* Reserved blocks count */
345         __le32  s_free_blocks_count;    /* Free blocks count */
346         __le32  s_free_inodes_count;    /* Free inodes count */
347         __le32  s_first_data_block;     /* First Data Block */
348         __le32  s_log_block_size;       /* Block size */
349         __le32  s_log_frag_size;        /* Fragment size */
350         __le32  s_blocks_per_group;     /* # Blocks per group */
351         __le32  s_frags_per_group;      /* # Fragments per group */
352         __le32  s_inodes_per_group;     /* # Inodes per group */
353         __le32  s_mtime;                /* Mount time */
…
411 };
```

若一个块大小为 4KB，则文件系统的最大值为 2^32 * 4KB=16TB

1.1.3 块组描述符表（GDT，Group Descriptor Table）

1) 块组描述符表由多个块组描述符（GD，Group Descriptor）组成，整个分区分成多少个块组就有多少个块组描述符。每个块组描述符存储一个块组的描述信息，例如在这个块组中从哪里开始是 inode 表，从哪里开始时数据块，空闲的 inode 和数据块还有多少个等等。

2) 和超级块类似，块组描述符表在每个块组的开头也都有一份拷贝，这些信息是非常重要的，一旦超级块意外损坏就会丢失整个分区的信息，一旦块组描述符意外损坏就会丢失整个块组的数据，因此它们都有多份拷贝。默认情况下，只有第一个块组的块组描述符会被系统内核使用，其他块组的超级块可以在 e2fsck 之类的程序对磁盘上的文件系统进行一致性检查时使用，这样当第一个块组的开头意外损坏时就可以使用其他拷贝来恢复，从而减少数据丢失。

3) 每个块组描述符占 32 个字节，块组描述表则占用多个块大小，具体数量不确定，由分区的大小和块大小确定。

4) 在 ext2 文件系统中，块组描述符通过一个名为 ext2_group_desc 的结构进行描述，如下所示（引用自 Kernel 的/root/include/linux/ext2_fs.h）：

```
133 /*
134  * Structure of a blocks group descriptor
135  */
136 struct ext2_group_desc
137 {
```

```
138         __le32  bg_block_bitmap;        /* Blocks bitmap block */
139         __le32  bg_inode_bitmap;        /* Inodes bitmap block */
140         __le32  bg_inode_table;         /* Inodes table block */
141         __le16  bg_free_blocks_count;   /* Free blocks count */
142         __le16  bg_free_inodes_count;   /* Free inodes count */
143         __le16  bg_used_dirs_count;     /* Directories count */
144         __le16  bg_pad;
145         __le32  bg_reserved[3];
146 };
```

1.1.4 块位图（Block Bitmap）

1) 在 ext2 文件系统中块组中的块是这样利用的：超级块、块组描述表、块位图、inode 位图、inode 表这几部分存储该块组的描述信息；数据块（Data Block）存储所有文件的数据；

2) 假设某个分区的块大小为 1024 字节，某个文件时 2049 字节，那么就需要三个数据块来存储这个文件，即使第三个块只存了一个字节也需要占用一个整块。

3) 块位图就是用来描述整个块组中哪些块已用，哪些块是空闲的。块位图占一个块，其中每个 bit 代表本块组的一个块，这个 bit 为 1 表示该块已用，这个 bit 为 0 表示该块空闲可用。

4) 使用 df 命令统计分区的已用空间速度非常块是因为只需要查看每个块组的块位图即可，不需要搜索真个分区。相反，使用 du 命令查看一个较大目录的已用空间就非常慢，因为其不可避免地要搜索真个目录的所有文件。

5) 至于一个分区中到底有多少个块组，主要的限制在于块位图本身必须只占一个块，因此块组的个数这取决于两个因素：分区大小和块大小。最终的计算公式如下：

   分区的块组数=分区大小/（块大小*8）

   注：格式化时可以用 mkfs 命令的-g 参数指定一个块组有多少个块，但是通常不需要手动指定，mkfs 工具会计算出最优的数值。

1.1.5 索引节点位图（inode Bitmap）

inode 位图和块位图类似，用来描述整个块组中哪些 inode 已用，哪些 inode 未使用。inode 位图本身占一个块，其中每个 bit 代表本块组的一个 inode，这个 bit 为 1 表示该 inode 已用，这个 bit 为 0 表示该 inode 未使用。

1.1.6 索引节点表（inode Table）

1) 索引节点表由多个索引节点（inode）组成，每个索引节点大小为 128 个字节。

2) 一个文件除了数据需要存储之外，一些描述信息也需要存储，例如文件类型、权限、文件大小等等（也就 ls -l 命令看到的信息），这些信息都存在 indoe 中而不是数据块（Data Block）中。每个文件都有一个 inode 中，一个块组中的所有 inode 组成了 inode 表。

3) inode 表占多少个块在格式化时就要决定并写入块组描述符中。mke2fs 格式化工的默认策略是一个块组有多少个 8KB 就分配多少个 inode。这样，若这个分区中平均每个文件的大小是 8KB，当分区存满的时候 inode 表会得到充分的利用，数据块也不浪费；如果这个分区存的都是很大的文件，则数据块用完的时候 inode 则会有一些浪费；如果这个分区存的都是很小的文件，则有可能数据块还用完 indoe 就已经用完了，数据块可能有很大的浪费。

4) 如果在格式化时能够对这个分区以后要存储的文件大小做一个预测，可以使用 mkfs 命令的-i 参数手动指定每多少个字节分配一个 inode。

5) 在 ext2 文件系统中，索引节点通过一个名为 ext2_inode 的结构进行描述，如下所示（引用自 Kernel 的/root/include/linux/ext2_fs.h）：

```
208 /*
209  * Structure of an inode on the disk
210  */
211 struct ext2_inode {
212         __le16  i_mode;         /* File mode */
213         __le16  i_uid;          /* Low 16 bits of Owner Uid */
214         __le32  i_size;         /* Size in bytes */
215         __le32  i_atime;        /* Access time */
216         __le32  i_ctime;        /* Creation time */
217         __le32  i_mtime;        /* Modification time
218         __le32  i_dtime;        /* Deletion Time */
219         __le16  i_gid;          /* Low 16 bits of Group Id */
220         __le16  i_links_count;  /* Links count */
221         __le32  i_blocks;       /* Blocks count */
222         __le32  i_flags;        /* File flags */
…
234         __le32  i_block[EXT2_N_BLOCKS];/* Pointers to blocks */
…
263 };
```

这里的块是以 512 字节来计算的，并非格式化文件系统指定的块大小，因此单个文件的最大值为 2^32*512B=2TB

该域保存了数据存放在数据块的位置

1.1.7 数据块（Data Block）

根据不同的文件类型有以下几种情况：

1） 对于常规文件，文件的数据存储在数据块中。

2） 对于目录，该目录下的所有文件名和目录名存储在数据块中。

注： a：目录也是一种文件，是一种特殊类型的文件。

b：文件名保存在它所在目录的数据块中，除文件名外，ls －l 命令看到的其他信息都存在该文件的 inode 中。

3） 对于符号链接文件，如果目标路径名较短（小于 60 个字符）则直接保存在 inode 中以便快速地查找，如果目标路径名较长则分配一个数据块来保存。

4） 对于硬链接文件，与原文件采用相同的 inode，仅在所属目录的数据块中有一个目录项记录。

注： a：不能对目录建立硬链接

b：不能建立跨文件系统的硬链接

5） 设备文件、FIFO 和 socket 等特殊文件没有数据块，设备文件的主设备号和次设备号保存在 inode 中。

6) 在 ext2 文件系统中，目录项通过一个名为 ext2_dir_entry_2 的结构进行描述，如下所示（引用自 Kernel 的/root/include/linux/ext2_fs.h）：

```
517 /*
518  * The new version of the directory entry.  Since EXT2 structures are
519  * stored in intel byte order, and the name_len field could never be
520  * bigger than 255 chars, it's safe to reclaim the extra byte for the
521  * file_type field.
522  */
523 struct ext2_dir_entry_2 {
524         __le32  inode;                  /* Inode number */
525         __le16  rec_len;                /* Directory entry length */
526         __u8    name_len;               /* Name length */
527         __u8    file_type;
528         char    name[EXT2_NAME_LEN];    /* File name */
529};
```

1.2 数据块寻址

在索引节点表中介绍的 ext2_inode 结构保存文件的各种描述信息，其中 i_block 域是一个大小为 EXT2_N_BLOCKS（通常来说，其值为 15）的数组，其中保存的就是真正存放文件数据的数据块位置。

在 ext2 文件系统中，采用了直接寻址和间接寻址两种方式来对数据进行寻址，原理如下图所示：（假设块大小为 b 个字节）

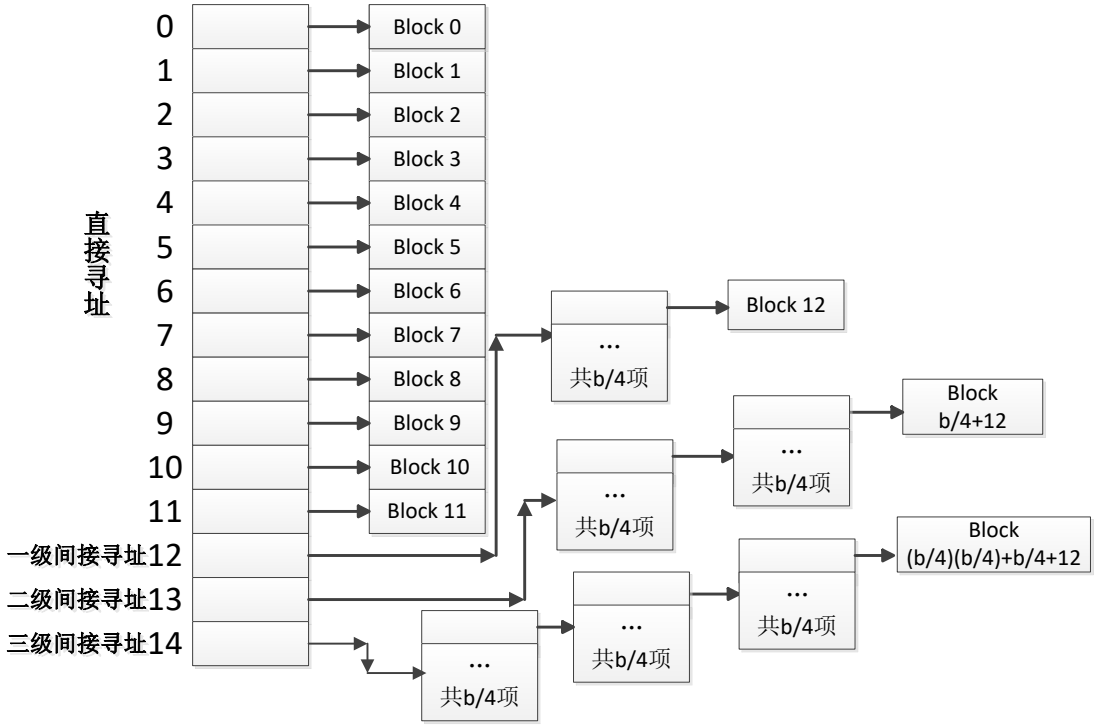

1.2.1 直接寻址与间接寻址

1) 对于 i_block 的前 12 个元素（i_block[0]到 i_block[11]）来说，其中存放的就是实际的数据块号，即对应于文件的 0 到 11 块。这种方式称为直接寻址。

2) 对于 i_block 的第 13 个元素（i_block[12]）来说，其中存放的是另外一个数据块的逻辑块号；这个块中并不存放真正的数据，而是存放真正保存数据的数据块的块号。由于每个块号需要使用 4 个字节表示，因此这种寻址方式可以访问的对应文件的块号范围为 12 到(b/4)+11，这种寻址方式称为间接寻址。

3) 对于 i_block 的第 14 个元素（i_block[13]）来说，其中存放的也是另外一个数据块的逻辑块号。不过其则利用了二级间接索引，第三级数组存放的才是真正保存文件的逻辑块号，这种寻址方式称为二次间接寻址，对应文件块号的寻址范围为 b/4+12 到(b/4)^2+(b/4)+11。

4) 对于 i_block 的第 15 个元素（i_block[14]）来说，则利用了三级间接寻址，第四级数组中存放的才是真正保存文件的块号，其寻址范围为(b/4)^2+12 到(b/4)^3+(b/4)^12+(b/4)+11。

5) 可见，这种寻址方式对于访问不超过 12 个数据块的小文件事非常快的，访问文件中的任意数据只需要两次读盘操：一次读 inode；一次读数据；而访问大文中的数据则需要最多五次读盘操作：indoe、一级间接寻址、二级间接寻址、三级间接寻址、数据块。

1.2.2 数据块寻址能力

ext2 文件系统可以支持 1024、2048 和 4096 字节三种大小的块，其对应的寻址能力如下表所示：

块大小	直接寻址	间接寻址	二次间接寻址	三次间接寻址
1024B	12KB	268KB	64.26MB	16.06GB
2048B	24KB	1.02MB	513.02MB	265.5GB
4096B	48KB	4.04MB	4GB	4TB

1.2.3 数据块寻址过程

假设有一个文件/opt/file，我们要使用 cat 命令把其内容打印到终端上，其数据块的寻址过程如下：

1） 读出 inode 表中第 2 项，也就是根目录的 inode，从中找出根目录的数据块的位置
2） 从根目录的数据块中找出文件名为 opt 的记录，从记录中读出它的 inode 号
3） 读出 opt 目录的 inode，从中找出它的数据块的位置
4） 从 opt 目录的数据块中找出文件名为 file 的记录，从记录中读出它的 inode 号
5） 读出 file 文件的 inode，从中找出它的数据的位置
6） 输出其内容到终端

1.3 实例剖析

1.3.1 查看文件系统的布局

1） dumpe2fs 工具
首先使用 parted 命令格式一个分区大小为 1MB，然后使用 mkfs.ext2 来创建一个 ext2 文件系统，最后使用 dumpe2fs 命令来查看文件系统的超级块和块组描述符表中的信息，如下所示：

```
[root@localhost /]# dumpe2fs  /dev/sde1
dumpe2fs 1.41.12 (17-May-2010)
Filesystem volume name:   <none>
Last mounted on:          <not available>
Filesystem UUID:          69525cc0-d9f7-4ea6-86b3-a0e1b94e22cf
Filesystem magic number:  0xEF53
Filesystem revision #:    1 (dynamic)
Filesystem features:      ext_attr resize_inode dir_index filetype
                          sparse_super
Filesystem flags:         signed_directory_hash
Default mount options:    (none)
Filesystem state:         not clean
```

```
Errors behavior:          Continue
Filesystem OS type:       Linux
Inode count:              128
Block count:              976
Reserved block count:     48
Free blocks:              938
Free inodes:              117
First block:              1
Block size:               1024
Fragment size:            1024
Reserved GDT blocks:      3
Blocks per group:         8192
Fragments per group:      8192
Inodes per group:         128
Inode blocks per group:   16
Filesystem created:       Wed Jan 22 02:04:10 2014
Last mount time:          Wed Jan 22 02:04:23 2014
Last write time:          Wed Jan 22 02:04:23 2014
Mount count:              1
Maximum mount count:      21
Last checked:             Wed Jan 22 02:04:10 2014
Check interval:           15552000 (6 months)
Next check after:         Mon Jul 21 03:04:10 2014
Reserved blocks uid:      0 (user root)
Reserved blocks gid:      0 (group root)
First inode:              11
Inode size:               128
Default directory hash:   half_md4
Directory Hash Seed:      fbd896e5-47aa-4781-be0a-a0dd2e9bf7b3
Group 0: (Blocks 1-975)
    Primary superblock at 1, Group descriptors at 2-2
    Reserved GDT blocks at 3-5
    Block bitmap at 6 (+5), Inode bitmap at 7 (+6)
    Inode table at 8-23 (+7)
    938 free blocks, 117 free inodes, 2 directories
    Free blocks: 38-975
    Free inodes: 12-128
```

从上图可以看出：

1) 块大小是 1024 字节，共有 976 个块
2) 第 0 个块是启动块，因此 Group 0 占据第 1 个块到第 975 个块
3) 块位图占一个块，共有 1024*8=8192 个 bit，足够表示这 975 个块了
4) 共有 128 inode，每个 inode 占 128 字节

…

2) hexdump 命令

使用 hexdump 命令来查看文件系统的所有字节，来深入理解文件系统的布局，如下所示：

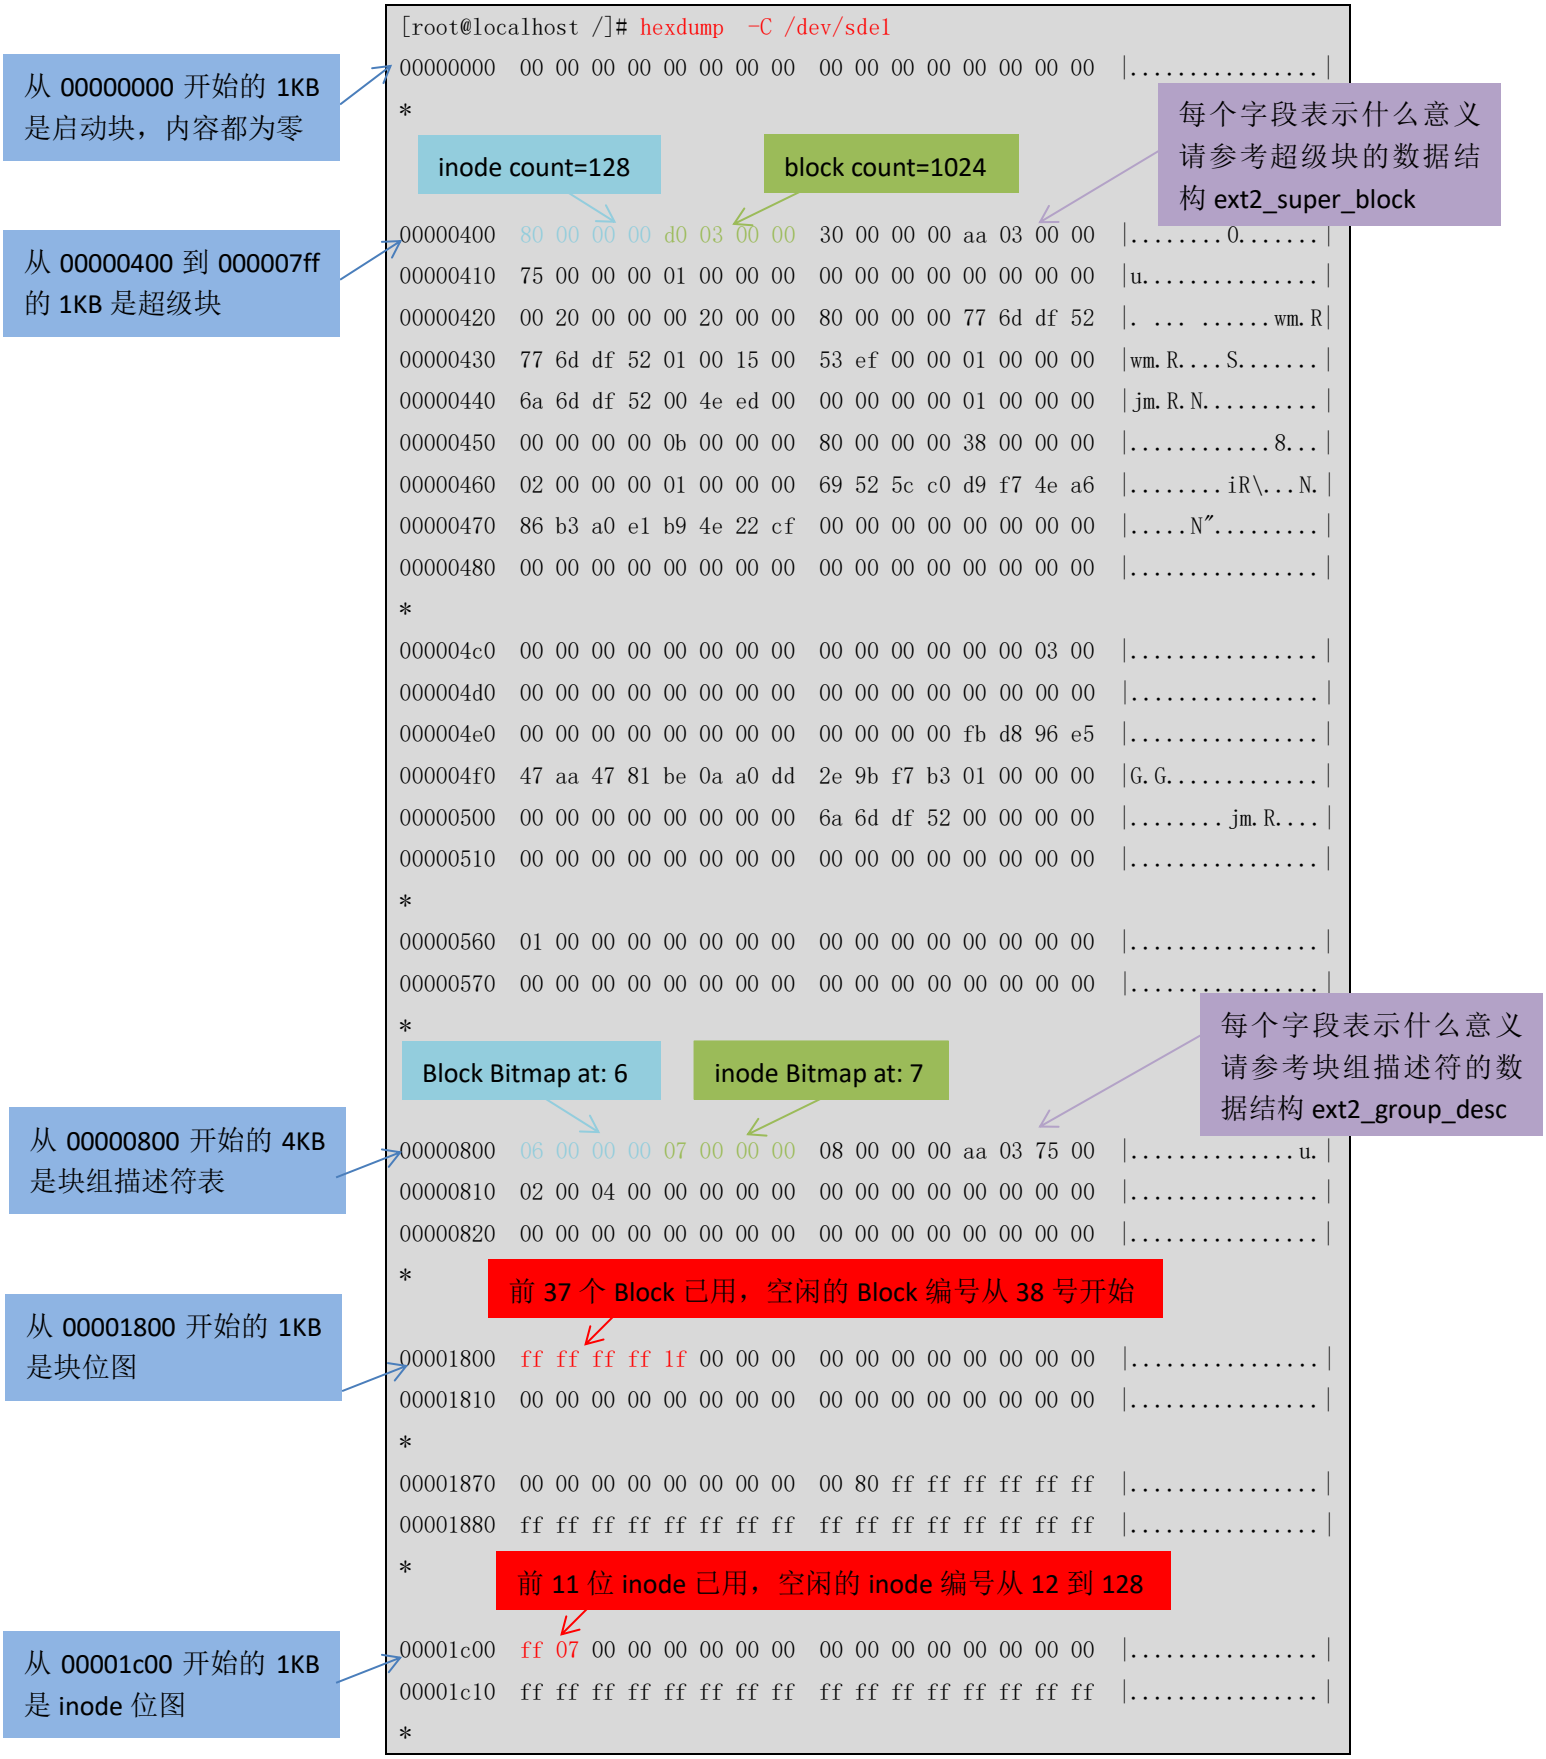

从 00002000 开始的 7KB 是 inode Table

从 00002080 开始的 128 个字节是 inode 号为 2 的索引节点，即根目录的索引节点

从 00006000 开始的 1KB（目录大小为 block 的整数倍）为根目录的数据块

st_mode=040755

User=0000,即 root 用户

每个字段表示什么意义请参 inode 的数据结构 ext2_inode

inode 号为 2

目录项的长度为 12

每个字段表示什么意义请参目录项的数据结构 ext2_dir_entry_2

```
00002000  00 00 00 00 00 00 00 00  6a 6d df 52 6a 6d df 52  |........jm.Rjm.R|
00002010  6a 6d df 52 00 00 00 00  00 00 00 00 00 00 00 00  |jm.R............|
00002020  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00002080  ed 41 00 00 00 04 00 00  6a 6d df 52 6a 6d df 52  |.A......jm.Rjm.R|
00002090  6a 6d df 52 00 00 00 00  00 00 03 00 02 00 00 00  |jm.R............|
000020a0  00 00 00 00 00 00 00 00  18 00 00 00 00 00 00 00  |................|
000020b0  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00002300  80 81 00 00 00 30 04 04  6a 6d df 52 6a 6d df 52  |.....0..jm.Rjm.R|
00002310  6a 6d df 52 00 00 00 00  00 00 01 00 08 00 00 00  |jm.R............|
00002320  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00002350  00 00 00 00 00 00 00 00  00 00 00 00 25 00 00 00  |............%...|
00002360  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00002500  c0 41 00 00 00 30 00 00  6a 6d df 52 6a 6d df 52  |.A...0..jm.Rjm.R|
00002510  6a 6d df 52 00 00 00 00  00 00 02 00 18 00 00 00  |jm.R............|
00002520  00 00 00 00 00 00 00 00  19 00 00 00 1a 00 00 00  |................|
00002530  1b 00 00 00 1c 00 00 00  1d 00 00 00 1e 00 00 00  |................|
00002540  1f 00 00 00 20 00 00 00  21 00 00 00 22 00 00 00  |.... ...!..."...|
00002550  23 00 00 00 24 00 00 00  00 00 00 00 00 00 00 00  |#...$...........|
*
00006000  02 00 00 00 0c 00 01 02  2e 00 00 00 02 00 00 00  |................|
00006010  0c 00 02 02 2e 2e 00 00  0b 00 00 00 e8 03 0a 02  |................|
00006020  6c 6f 73 74 2b 66 6f 75  6e 64 00 00 00 00 00 00  |lost+found......|
00006030  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00006400  0b 00 00 00 0c 00 01 02  2e 00 00 00 02 00 00 00  |................|
00006410  f4 03 02 02 2e 2e 00 00  00 00 00 00 00 00 00 00  |................|
00006420  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00006800  00 00 00 00 00 04 00 00  00 00 00 00 00 00 00 00  |................|
00006810  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
00006c00  00 00 00 00 00 04 00 00  00 00 00 00 00 00 00 00  |................|
00006c10  00 00 00 00 00 00 00 00  00 00 00 00 00 00 00 00  |................|
*
```

从上图中的各项数据来看，与之前的分析以及 dumpe2fs 命令的输出结果一致。

1.3.2 恢复已删除的文件

在 ext2 文件系统中，文件被删除时其对应的数据块并不会被真正的删除，因此通过一些技术手段完全有可能将被删除的文件恢复回来。接下来就来进行分析：

1） 删除文件的原理

a) 目录是一种特殊的文件，其索引节点的结构与普通文件一样，唯一的区别是目录中的数据都是按照 ext2_dir_entry_2 结构存储在数据块的。先来看一个已准备好的目录：

```
[root@localhost / ]# debugfs /dev/sde1
debugfs 1.41.12 (17-May-2010)
debugfs:  ls -l
     2   40755 (2)      0      0    1024 23-Jan-2014 13:38 .
     2   40755 (2)      0      0    1024 23-Jan-2014 13:38 ..
    11   40700 (2)      0      0   12288 23-Jan-2014 13:35 lost+found
    12   40755 (2)      0      0    1024 23-Jan-2014 13:36 testdir1
    13   40755 (2)      0      0    1024 23-Jan-2014 13:36 testdir2
    15  100644 (1)      0      0      12 23-Jan-2014 13:37 testfile
    16  100644 (1)      0      0      75 23-Jan-2014 13:38 testfile2
debugfs:  stat <2>
    Inode: 2   Type: directory    Mode:  0755   Flags: 0x0
    Generation: 0    Version: 0x00000000
    User:     0   Group:     0   Size: 1024
    File ACL: 0    Directory ACL: 0
    Links: 3   Blockcount: 2
    Fragment:  Address: 0    Number: 0    Size: 0
    ctime: 0x52e08b6d -- Thu Jan 23 11:24:29 2014
    atime: 0x52e08b6e -- Thu Jan 23 11:24:30 2014
    mtime: 0x52e08b6d -- Thu Jan 23 11:24:29 2014
    BLOCKS:
    (0):24
    TOTAL: 1
debugfs:  stat <15>
    Inode: 15   Type: regular    Mode:  0644   Flags: 0x0
    Generation: 762856613    Version: 0x00000000
    User:     0   Group:     0   Size: 12
    File ACL: 0    Directory ACL: 0
    Links: 1   Blockcount: 2
    Fragment:  Address: 0    Number: 0    Size: 0
    ctime: 0x52e0ab88 -- Thu Jan 23 13:41:28 2014
    atime: 0x52e0aa84 -- Thu Jan 23 13:37:08 2014
    mtime: 0x52e0aa84 -- Thu Jan 23 13:37:08 2014
    BLOCKS:
    (0):64
    TOTAL: 1
```

根目录的数据块所在位置

b) 备份根目录的数据块

```
[root@localhost /]# dd if=/dev/sde1 of=/block.24.orig bs=1024 count=1 skip=24
1+0 records in
1+0 records out
1024 bytes (1.0 kB) copied, 0.00032152 s, 3.2 MB/s
```

c) 写一个小程序，读取目录数据块中的数据

```
/*Program:
 *   read_dir_entry.c
 *   read directory's data block and output to terminal
 *History:
 *     renyl   2014/1/23   0.1version
 */

#include <stdio.h>
#include <stdlib.h>
#include <ext2fs/ext2_fs.h>

/*custom data struct similar to ext2_dir_entry_2*/
struct ext2_dir_entry_part{
        __u32   inode;
        __u16   rec_len;
        __u8    name_len;
        __u8    file_type;
};

void usage()
{
        printf("./read_dir_entry  <dir_entry_filename> <dir_entry_size>\n");
        exit(1);
}

int main(int argc, char* argv[])
{
        struct ext2_dir_entry_part  dep;
        struct ext2_dir_entry_2     de;

        char *filename = NULL;
        FILE *fp = NULL;

        int de_size = 0;
        int len = 0;
        int rtn = 0;
```

```
        if (argc < 3)
        {
                printf("Too few parameters!\n");
                usage();
        }

        filename = argv[1];
        de_size = atoi(argv[2]);

        fp = fopen(filename,"r");
        if (!fp)
                printf("can't open file: %s\n",filename);

        printf("offset | inode_number | rec_len | name_len | file_type |
name\n");
        printf("=======================================\n");

        while ( rtn = fread(&dep, sizeof(struct ext2_dir_entry_part), 1, fp) )
        {
                if (dep.rec_len <=0)
                {
                        fclose(fp);
                        exit(3);
                }

                fseek(fp, 0 - sizeof(struct ext2_dir_entry_part), SEEK_CUR);

                /*dir_entry need 4Byte alignment.*/
                fread(&de,((int)(dep.name_len+3)/4)*4 \
                     + sizeof(struct ext2_dir_entry_part), 1 ,fp);

                de.name[de.name_len]='\0';

               printf("%6d: %10d%10d%10d%10d           %s\n",\
               len, de.inode, de.rec_len, de.name_len, de.file_type, de.name);

               len+=dep.rec_len;

                if (len >= de_size - sizeof(struct ext2_dir_entry_part))
                {
                        fclose(fp);
                        return 0;
                }
        }
```

```
        fclose(fp);
        return 0;
}
```

d) 对比文件 testfile 被删除前后索引节点的变化以及所属目录数据块的变化

```
[root@localhost /]# gcc -g read_dir_entry.c  -o read_dir_entry
[root@localhost /]# ./read_dir_entry  block.24  1024
offset | inode_number | rec_len | name_len | file_type | name
=================================================
 0:          2        12         1         2     .
12:          2        12         2         2     ..
24:         11        20        10         2     lost+found
44:         12        16         8         2     testdir1
60:         13        40         8         2     testdir2
100:         0        24        14         1     .testfile2.swp
124:        15        16         8         1     testfile
140:        16       908s         9         1     testfile2
[root@localhost /]# cat /home/renyl/mountdir/testfile
hello world
[root@localhost /]# rm -rf /home/renyl/mountdir/testfile
[root@localhost /]# umount /dev/sde1
[root@localhost /]# mount /dev/sde1 /home/renyl/mountdir
[root@localhost /]# dd if=/dev/sde1  of=/block.24.deleted  bs=1024 count=1
skip=24
1+0 records in
1+0 records out
1024 bytes (1.0 kB) copied, 0.00032152 s, 3.2 MB/s
[root@localhost /]# ./read_dir_entry  block.24.deleted  1024
offset | inode_number | rec_len | name_len | file_type | name
=================================================
  0:          2        12         1         2     .
 12:          2        12         2         2     ..
 24:         11        20        10         2     lost+found
 44:         12        16         8         2     testdir1
 60:         13        56         8         2     testdir2
116:         0        24        14         1     .testfile2.swp
140:         0        16         8         1     testfile
156:        16       908         9         1     testfile2
[root@localhost / ]# debugfs /dev/sde1
debugfs 1.41.12 (17-May-2010)
debugfs:  stat <15>
      Inode: 15   Type: regular    Mode:  0644   Flags: 0x0
      Generation: 762856613    Version: 0x00000000
```

该文件是在我编辑文件 testfile2 时，系统自动保存的

重新挂载是为了确保删除操作会被同步到磁盘上的数据块中

索引节点被清空了，这也就是为什么 ls 命令无法显示被删除后的文件

```
      User:     0   Group:     0   Size: 12
      File ACL: 0    Directory ACL: 0
      Links: 0   Blockcount: 2
      Fragment:  Address: 0    Number: 0    Size: 0
      ctime: 0x52e0ab88 -- Thu Jan 23 13:41:28 2014
      atime: 0x52e0aa84 -- Thu Jan 23 13:37:08 2014
      mtime: 0x52e0aa84 -- Thu Jan 23 13:37:08 2014
      dtime: 0x52e0ab88 -- Thu Jan 23 13:41:28 2014
      BLOCKS:
      (0):64
      TOTAL: 1
[root@localhost /]# cd /home/renyl/mountdir/
[root@localhost mountdir]# ls -ali
total 20
    2 drwxr-xr-x  5 root root  1024 Jan 23 13:41 .
32792 drwxr-xr-x.  7 root root  4096 Jan 23 06:55 ..
   11 drwx------  2 root root 12288 Jan 23 13:35 lost+found
   12 drwxr-xr-x  2 root root  1024 Jan 23 13:36 testdir1
   13 drwxr-xr-x  2 root root  1024 Jan 23 13:36 testdir2
   16 -rw-r--r--  1 root root    75 Jan 23 13:38 testfile2
```

由上表可以看出，文件 testfile 被删除后，索引节点和所在目录的数据块都发生了变化：

- 索引节点：
  a）设置了 i_dtime 域，该域只有文件被删除时才设置
  b）硬链接数（link）被设置为零
  c）将 Block Bitmap 和 inode Bitmap 中所对应的 bit 设置为 0，即可用状态
- 所在目录数据块：
  a） 将文件的索引节点号清空
  b） 将文件的 rec_len 长度合并到前一项

由于文件被删除时，其数据块没有被删除，以及索引节点中的重要信息没有被删除（如文件属性、大小、访问权限以及数据块的块号），因此可以把已删除的文件恢复出来。

2）删除文件的恢复

```
[root@localhost mountdir]# debugfs /dev/sde1
debugfs 1.41.12 (17-May-2010)
debugfs:  lsdel
 Inode  Owner  Mode    Size      Blocks   Time deleted
    14      0 100600  12288     12/    12 Thu Jan 23 13:38:04 2014
    15      0 100644     12      1/     1 Thu Jan 23 13:41:28 2014
2 deleted inodes found.
debugfs:  dump <15> testfile.bak
debugfs:  q
[root@localhost mountdir]# ls -ali
```

```
total 21
    2 drwxr-xr-x  5 root root  1024 Jan 23 15:34 .
32792 drwxr-xr-x.  7 root root  4096 Jan 23 06:55 ..
   11 drwx------  2 root root 12288 Jan 23 13:35 lost+found
   12 drwxr-xr-x  2 root root  1024 Jan 23 13:36 testdir1
   13 drwxr-xr-x  2 root root  1024 Jan 23 13:36 testdir2
   16 -rw-r--r--   1 root root    75 Jan 23 13:38 testfile2
   14 -rw-r--r--   1 root root    12 Jan 23 15:34 testfile.bak
[root@localhost mountdir]# cat  testfile.bak
hello world
```

debugfs 的 lsdel 命令去扫描磁盘上索引节点表中的所有索引节点，其中 i_dtime 不为空的项就被认为是已经删除的文件对对应的索引节点。使用 dump 命令可以恢复已删除的文件。

Linux 文件系统还存在一些特殊文件，如目录、链接文件，空洞文件等，对这些文件的恢复思路与普通文件类似。恢复系统中删除的文件是一个非常繁琐的过程，而工具 e2undel 可以用来方便地恢复文件系统中已删除的各种文件。

2 ext3 文件系统

2.1 产生的背景

1) ext2 文件系统具有较好的文件存取性能，是由于其采用了“文件系统缓存”的概念，可以加速文件的读写速度。然而，如果“文件系统缓存”中的数据尚未写入磁盘，机器就发生了断电等意外状况，就会造成磁盘数据不一致的情况，这会破坏磁盘数据的完整性（文件数据与元数据不一致）。

2) 为了确保数据的完整，在系统引导时，会自动检查文件系统上次是否是正常卸载的。如果是非正常卸载或者已经使用到一定的次数，就会自动运行 fsck 之类的程序强制进行一致性检查，并修复存在问题的地方，使 ext2 文件系统恢复到新的一致性状态。

3) 随着硬盘技术的发展，磁盘容量变得越来越大，对磁盘进行一致性检查可能会占用很长时间,这对于一些关键应用来说是无法忍受的,于是日志文件系统(Journal File System)的概念就应用而生了。

2.2 日志文件系统

2.2.1 日志文件系统的定义

日志文件系统：是指在文件系统发生变化时，先把相关信息写入一个被称为日志的区域，然后再把变化写入主文件系统的文件系统。在文件系统发生故障(如内核崩溃或突然停电)时，日志文件系统更容易保持一致性，并且可以较快恢复。

具体来说，就是在修改文件系统内容的同时（或之前），将修改变化记录到日志中，这样就可以在意外发生的情况下，就可以根据日志将文件系统恢复到一致状态。这些操作完全可以在重新挂载文件系统时来完成。因此，在重新启动机器时，并不需要对文件系统进行一致性检查，这样可以提高系统的可用程度。

2.2.2 日志文件系统的原理

1) 对文件系统进行修改时，需要进行很多操作。这些操作可能中途被打断，也就是说，这些操作不是“不可中断”（atomic）的，如果操作被打断，就可能造成文件系统出现不一致的状态。

2) 例如删除文件时，先要从目录树中移除文件的标示，然后收回文件占用空间。如果在这两步之间操作被打断，文件占用的空间就无法收回。文件系统认为它是被占用的，但实际上目录树种已经找不到使用它的文件了。

3) 在非日志文件系统中，要检查并修复类似的错误就必须对整个文件系统的数据结构进行检查。一般在挂载文件系统前，操作系统会检查它上次是否被成功卸载，如果没有，就会对其进行检查。如果文件系统很大，就会花费很长时间。

4) 为了避免这样的问题，日志文件系统分配了一个称为日志的区域来提前记录要对文件系统做的更改。在系统崩溃或突然掉电后，只要读取日志重新执行未完成的操作，文件系统就可以恢复一致。这种恢复是“原子操作”的，有如下几种情况：
   a) 不需要重新执行：这个事务被标记为已经完成
   b) 成功重新执行：根据日志记录，这个事务被重新执行
   c) 无法重新执行：这个事务会被撤销，就如同这个事务从来没有发生过
   d) 日志本身不完成：事务还没有被完全写入日志，它会被简单忽略

2.3 日志的分类

ext3 文件系统提供了 3 种日志模式：

1） 回写（data=writeback）：只有元数据被记录到日志中，数据被直接写入主文件系统中，这种模式速度最快，提供较好的性能，但也有较大的风险。例如，在增大文件时，数据还没写入就发生崩溃，那么文件系统恢复后文件后面就可能出现垃圾数据。

2） 顺序（data=ordered）：只有元数据被记录到日志中，但在日志被标记为提交前，数据会被写入文件系统。在这种模式下，如果在增大文件时，数据还未写入就发生崩溃，那么在恢复时这个事务会被简单的撤销，文件保持原来的状态。

3） 数据（data=journal）：元数据和文件内容都先被写入到日志中，然后再提交到主文件系统。这提高了安全性，但损失了性能，因为所有数据要写入两次。在这种模式下，如果增大文件时，发生崩溃，那么可能有两种情况：
   a） 日志完成：这时事务会被重新执行，修改会被提交到主文件系统
   b） 日志不完成：这时文件系统还未被修改，只需要简单放弃这个事务

不管哪种日志模式，这对于用户来说都是透明的，用户根本就察觉不到日志文件的存在，只是内核在挂载文件系统时会自动检查日志的内容，并采取相应的操作，将尚未提交到磁盘上的操作重新写入磁盘，从而确保文件系统的一致性。

2.4 ext3 与 ext2 的关系

ext3 最大的特性在于它完全兼容 ext2 文件系统，ext2 和 ext3 文件系统之间可以无缝地进行变换，二者在磁盘上采用完全相同的数据格式进行存储。

1）创建一个 ext3 和一个 ext2 文件系统，如下所示：

```
[root@localhost /]# mkfs.ext3  /dev/sde2
mke2fs 1.41.12 (17-May-2010)
Filesystem label=
```

```
OS type: Linux
Block size=4096 (log=2)
Fragment size=4096 (log=2)
Stride=0 blocks, Stripe width=0 blocks
61056 inodes, 243968 blocks
12198 blocks (5.00%) reserved for the super user
First data block=0
Maximum filesystem blocks=251658240
8 block groups
32768 blocks per group, 32768 fragments per group
7632 inodes per group
Superblock backups stored on blocks:
        32768, 98304, 163840, 229376

Writing inode tables: done
Creating journal (4096 blocks): done
Writing superblocks and filesystem accounting information: done

This filesystem will be automatically checked every 31 mounts or
180 days, whichever comes first.  Use tune2fs -c or -i to override.

[root@localhost /]# mkfs.ext2  /dev/sde3
mke2fs 1.41.12 (17-May-2010)
Filesystem label=
OS type: Linux
Block size=4096 (log=2)
Fragment size=4096 (log=2)
Stride=0 blocks, Stripe width=0 blocks
61056 inodes, 243968 blocks
12198 blocks (5.00%) reserved for the super user
First data block=0
Maximum filesystem blocks=251658240
8 block groups
32768 blocks per group, 32768 fragments per group
7632 inodes per group
Superblock backups stored on blocks:
        32768, 98304, 163840, 229376

Writing inode tables: done
Writing superblocks and filesystem accounting information: done

This filesystem will be automatically checked every 37 mounts or
180 days, whichever comes first.  Use tune2fs -c or -i to override.
```

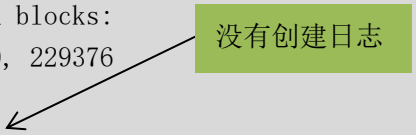

从上表可以看出，mkfs.ext3 命令额外在文件系统中使用 4096 个数据块创建了日志。

2） ext2 文件系统转换成 ext3 文件系统

```
[root@localhost /]# tune2fs -j /dev/sde3
tune2fs 1.41.12 (17-May-2010)
Creating journal inode: done
This filesystem will be automatically checked every 37 mounts or
180 days, whichever comes first.  Use tune2fs -c or -i to override.
[root@localhost /]# dumpe2fs  /dev/sde3
    Filesystem volume name:   <none>
    Last mounted on:          <not available>
    Filesystem UUID:          83da648b-4c0d-42cd-9890-320922b14d56
    Filesystem magic number:  0xEF53
    Filesystem revision #:    1 (dynamic)
    Filesystem features:         has_journal  ext_attr  resize_inode  dir_index
filetype sparse_super large_file
    Filesystem flags:         signed_directory_hash
    Default mount options:    (none)
    Filesystem state:         clean
    Errors behavior:          Continue
    Filesystem OS type:       Linux
    Inode count:              61056
    Block count:              243968
    Reserved block count:     12198
    Free blocks:              235724
    Free inodes:              61045
    First block:              0
    Block size:               4096
    Fragment size:            4096
    Reserved GDT blocks:      59
    Blocks per group:         32768
    Fragments per group:      32768
    Inodes per group:         7632
    Inode blocks per group:   477
    Filesystem created:       Fri Jan 24 11:33:32 2014
    Last mount time:          n/a
    Last write time:          Fri Jan 24 11:35:25 2014
    Mount count:              0
    Maximum mount count:      37
    Last checked:             Fri Jan 24 11:33:32 2014
    Check interval:           15552000 (6 months)
    Next check after:         Wed Jul 23 11:33:32 2014
    Reserved blocks uid:      0 (user root)
    Reserved blocks gid:      0 (group root)
```

创建日志

```
First inode:              11
Inode size:               256
Required extra isize:     28
Desired extra isize:      28
Journal inode:            8
Default directory hash:   half_md4
Directory Hash Seed:      ddc8cace-78d7-47f9-9998-996594fe77b8
Journal backup:           inode blocks
Journal features:         (none)
Journal size:             16M
Journal length:           4096
Journal sequence:         0x00000001
Journal start:            0
...
```

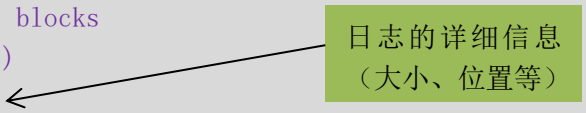

从上表可以看出，ext2 文件系统可以使用 tune2fs 命令平滑地转换成 ext3 文件系统。

2.5 文件恢复

1) 对于恢复删除的文件来说，需要关心的是文件在磁盘上的存储格式。实际上，ext3 在这方面完全兼容 ext2，以至于大部分支持 ext2 文件系统的工具都可以在 ext3 文件系统上使用。以存储目录项和索引节点使用的数据结构来看，如下所示：（引用自 Kernel 的/root/include/linux/ext3_fs.h）

```
285 /*
286  * Structure of an inode on the disk
287  */
288 struct ext3_inode {
289         __le16  i_mode;         /* File mode */
290         __le16  i_uid;          /* Low 16 bits of Owner Uid */
291         __le32  i_size;         /* Size in bytes */
292         __le32  i_atime;        /* Access time */
293         __le32  i_ctime;        /* Creation time */
294         __le32  i_mtime;        /* Modification time */
295         __le32  i_dtime;        /* Deletion Time */
296         __le16  i_gid;          /* Low 16 bits of Group Id */
297         __le16  i_links_count;  /* Links count */
298         __le32  i_blocks;       /* Blocks count */
299         __le32  i_flags;        /* File flags */
300         union {
301                 struct {
302                         __u32  l_i_reserved1;
303                 } linux1;
304                 struct {
```

```
305                     __u32   h_i_translator;
306             } hurd1;
307             struct {
308                     __u32   m_i_reserved1;
309             } masix1;
310     } osd1;                         /* OS dependent 1 */
311     __le32  i_block[EXT3_N_BLOCKS];/* Pointers to blocks */
312     __le32  i_generation;   /* File version (for NFS) */

…

671 /*
672  * The new version of the directory entry.  Since EXT3 structures are
673  * stored in intel byte order, and the name_len field could never be
674  * bigger than 255 chars, it's safe to reclaim the extra byte for the
675  * file_type field.
676  */
677 struct ext3_dir_entry_2 {
678     __le32  inode;                  /* Inode number */
679     __le16  rec_len;                /* Directory entry length */
680     __u8    name_len;               /* Name length */
681     __u8    file_type;
682     char    name[EXT3_NAME_LEN];    /* File name */
683 };
…
```

从上表可以看出，ext3 使用的两个数据结构 ext3_dir_entry_2 和 ext3_inode 与 ext2 并没有根本的区别，这正是 ext2 和 ext3 文件系统可以实现自由转换的基础。

ext3 和 ext2 文件系统具有这么好的兼容性和相似性，以至于数据块的寻址过程，文件系统的布局都基本一致。那么，文件的删除操作发生了变化吗？

2)　查看一下 ext3 文件系统删除文件前后索引节点信息的变化，如下所示：

```
[root@localhost mountdir]# debugfs /dev/sde2
debugfs 1.41.12 (17-May-2010)
debugfs:  ls -l
          2   40755 (2)      0      0    4096 24-Jan-2014 12:36 .
          2   40755 (2)      0      0    4096 24-Jan-2014 12:36 ..
         11   40700 (2)      0      0   16384 24-Jan-2014 11:23 lost+found
       7633   40755 (2)      0      0    4096 24-Jan-2014 12:35 dir1
      22897   40755 (2)      0      0    4096 24-Jan-2014 12:35 dir2
         12  100644 (1)      0      0      19 24-Jan-2014 12:36 testfile2
         13  100644 (1)      0      0      13 24-Jan-2014 12:35 testfile
```

```
debugfs:  stat <13>
    Inode: 13   Type: regular    Mode:  0644   Flags: 0x0
    Generation: 342839017    Version: 0x00000000
    User:     0   Group:     0   Size: 13
    File ACL: 0    Directory ACL: 0
    Links: 1   Blockcount: 8
    Fragment:  Address: 0    Number: 0    Size: 0
    ctime: 0x52e1ed9e -- Fri Jan 24 12:35:42 2014
    atime: 0x52e1eda1 -- Fri Jan 24 12:35:45 2014
    mtime: 0x52e1ed9e -- Fri Jan 24 12:35:42 2014
    Size of extra inode fields: 4
    BLOCKS:
    (0):30728
    TOTAL: 1
debugfs:  q
[root@localhost mountdir]# rm -rf testfile
[root@localhost mountdir]# cd /
[root@localhost /]# umount /dev/sde2
[root@localhost /]# mount /dev/sde2 /home/renyl/mountdir/
[root@localhost /]# debugfs /dev/sde2
debugfs 1.41.12 (17-May-2010)
debugfs:  ls -l
          2   40755 (2)      0      0    4096 24-Jan-2014 12:36 .
          2   40755 (2)      0      0    4096 24-Jan-2014 12:36 ..
         11   40700 (2)      0      0   16384 24-Jan-2014 11:23 lost+found
       7633   40755 (2)      0      0    4096 24-Jan-2014 12:35 dir1
      22897   40755 (2)      0      0    4096 24-Jan-2014 12:35 dir2
         12  100644 (1)      0      0      19 24-Jan-2014 12:36 testfile2

debugfs:  lsdel
     Inode  Owner  Mode    Size      Blocks   Time deleted
    0 deleted inodes found.
    debugfs:  stat <13>
    Inode: 13   Type: regular    Mode:  0644   Flags: 0x0
    Generation: 342839017    Version: 0x00000000
    User:     0   Group:     0   Size: 0
    File ACL: 0    Directory ACL: 0
    Links: 0   Blockcount: 0
    Fragment:  Address: 0    Number: 0    Size: 0
    ctime: 0x52e1edeb -- Fri Jan 24 12:36:59 2014
    atime: 0x52e1eda1 -- Fri Jan 24 12:35:45 2014
    mtime: 0x52e1edeb -- Fri Jan 24 12:36:59 2014
    dtime: 0x52e1edeb -- Fri Jan 24 12:36:59 2014
    Size of extra inode fields: 4
```

重新挂载是为了确保删除操作会被同步到磁盘上的数据块中

lsdel 命令已无法显示删除的文件

文件大小、硬链接数以及占用块数都被清空了

```
    BLOCKS:

debugfs:  q
[root@localhost mountdir]#
```

最为关键的是，存储数据所在数据块的块号被清空了

从上表可以看出，ext3 在删除文件时做了如下操作：

a) 设置了删除时间 i_dtime 域
b) 将硬链接数设置为 0
c) 将文件大小(size)和占用块数（Blockcount）都设置为 0
d) 清空存储文件数据的数据（i_block 数组）
e) 将父目录项中该文件对应的项中的索引节点号设置为 0，并扩展前一项，使其包含该项所占用的空间

这两点这正是 ext3 文件系统与 ext2 文件系统在删除文件时最重要的区别

b）和 c）两部分对于恢复被删除文件的用途至关重要。因为缺少了文件大小和数据块位置的信息，尽管文件数据依然完好的保存在磁盘上，但是没有任何线索能够说明这个文件的数据块被存储在哪个磁盘块上以及这些数据的相互顺序等信息。这也是使用 debugfs 的 dump 命令在 ext3 文件系统中并不能恢复已删除文件的原因。

这样，是否意味着 ext3 文件系统中删除的文件就无法恢复了呢？基于这样一个事实：“在删除文件时，并不会将文件数据真正从磁盘上删除”，因此可以采用一些技术手段来尝试恢复已删除的文件。

3) 解决方法

在删除文件的同时，除了记录文件名、磁盘设备、索引节点信息之外，把文件大小、数据块位置等重要信息也同时记录下来，这样就可以根据日志文件中的元数据信息完美地恢复文件了。

具体操作可以通过设置环境变量 LD_PRELOAD=***.so 来捕捉一些底层的系统调用（如 unlink、rmdir），修改删除文件的具体操作，把文件大小和数据位置这样的重要信息保存起来，这样就完全可以把删除的文件恢复出来。

这里推荐一个工具 ext3grep 可以完美地恢复所删除的文件，具体信息参考这里（http://carlo17.home.xs4all.nl/howto/undelete_ext3.html）

3 ext4 文件系统

3.1 ext4 产生的背景

1) 存储容量问题：随着硬盘存储容量越来越大以及在线重新调整特性的支持，ext3 面临的可扩充性压力越来越大。在 ext3 文件系统中，如果使用 4KB 大小的数据库，所支持的最大文件系统为 16TB，这是由于它使用了 32 位的块号所决定的（2^32＊4KB=16TB）。

2) 性能方面问题：ext3 文件系统修复时（fsck）花费时间太长以及读写速度要慢于其他文件系统（如 XFS、JFS）。

3.2 ext4 的新特性

3.2.1 更大的文件系统

1) ext4 采用 48 位的块号取代 ext3 原来的 32 位块号，这样可以增大文件系统的容量。如果使用 4KB 大小的数据块时，ext4 可以支持最大 2^48＊4KB=2^50KB=1EB 的文件系统。

2) 将块号从 32 位修改为 48 位之后，存储元数据的结构都必须相应地发生变化，主要包括超级块和组描述符。如下所示（引用自 Kernel 的/root/fs/ext4/ext4.h）：

```
207 /*
208  * Structure of a blocks group descriptor
209  */
210 struct ext4_group_desc
211 {
212         __le32  bg_block_bitmap_lo;     /* Blocks bitmap block */
213         __le32  bg_inode_bitmap_lo;     /* Inodes bitmap block */
214         __le32  bg_inode_table_lo;      /* Inodes table block */
215         __le16  bg_free_blocks_count_lo;/* Free blocks count */
216         __le16  bg_free_inodes_count_lo;/* Free inodes count */
217         __le16  bg_used_dirs_count_lo;  /* Directories count */
218         __le16  bg_flags;               /* EXT4_BG_flags (INODE_UNINIT,
etc) */
219         __u32   bg_reserved[2];         /* Likely block/inode bitmap
checksum */
220         __le16  bg_itable_unused_lo;    /* Unused inodes count */
221         __le16  bg_checksum;            /* crc16(sb_uuid+group+desc) */
222         __le32  bg_block_bitmap_hi;     /* Blocks bitmap block MSB */
223         __le32  bg_inode_bitmap_hi;     /* Inodes bitmap block MSB */
224         __le32  bg_inode_table_hi;      /* Inodes table block MSB */
```

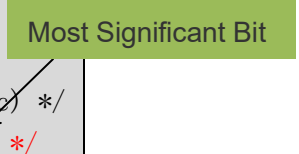

```
225         __le16  bg_free_blocks_count_hi;/* Free blocks count MSB */
226         __le16  bg_free_inodes_count_hi;/* Free inodes count MSB */
227         __le16  bg_used_dirs_count_hi;  /* Directories count MSB */
228         __le16  bg_itable_unused_hi;    /* Unused inodes count MSB */
229         __u32   bg_reserved2[3];
230 };
…
888 /*
889  * Structure of the super block
890  */
891 struct ext4_super_block {
892 /*00*/  __le32  s_inodes_count;         /* Inodes count */
893         __le32  s_blocks_count_lo;      /* Blocks count */
894         __le32  s_r_blocks_count_lo;    /* Reserved blocks count */
895         __le32  s_free_blocks_count_lo; /* Free blocks count */
896 /*10*/  __le32  s_free_inodes_count;    /* Free inodes count */
897         __le32  s_first_data_block;     /* First Data Block */
898         __le32  s_log_block_size;       /* Block size */
899         __le32  s_obso_log_frag_size;   /* Obsoleted fragment size */
…
962         /* 64bit support valid if EXT4_FEATURE_COMPAT_64BIT */
963 /*150*/ __le32  s_blocks_count_hi;      /* Blocks count */
964         __le32  s_r_blocks_count_hi;    /* Reserved blocks count */
965         __le32  s_free_blocks_count_hi; /* Free blocks count */
…
978 };
```

有上图可知：

a) 在 ext4_group_desc 结构体中引入了 7 个字段（红色字体），它们分别表示相应字段的高 16 位，将它们扩充到 48 位。

b) 在 ext4_super_desc 结构体中引入了 3 个字段（红色字体），它们分别表示相应字段的高 32 位，将它们扩充 64 位。

另外，由于日志中要记录所修改数据块的块号，因此 JBD（Journaling Block Device）也需要相应地支持 48 位的块号。

3) 采用 48 位块号取代原来的 32 位块号之后，文件系统的最大值还受文件系统中最多块数的制约，这是由于 ext3 原来采用的结构决定的。回想一下，在 ext3 中，所有的块组描述符信息都被保存在第一个块组中，因此以缺省的 128MB（2^27B）大小的块组为例，最多能够支持 2^21 个块组（由于 ext4 每个组描述符占 64 个字节，2^27B / 64B = 2^21），最大支持的文件系统大小为 2^21 * 2^27B = 2^48=256TB。为了解决这个问题，ext4 采用了下面将介绍的元组块。

3.2.2 元组块

所谓元组块是指：将块组描述符存储在一个数据块中的一些连续块组。以 128MB 的块组（数据块为 4KB）为例，ext4 中每个元块组可以包括 4096B / 64B = 64 个块组（ext4 中每个组描述符占 64 个字节），因此每个元组块的大小是 64 * 128MB = 8GB。

ext4 文件系统的在磁盘上的存储布局如下所示：

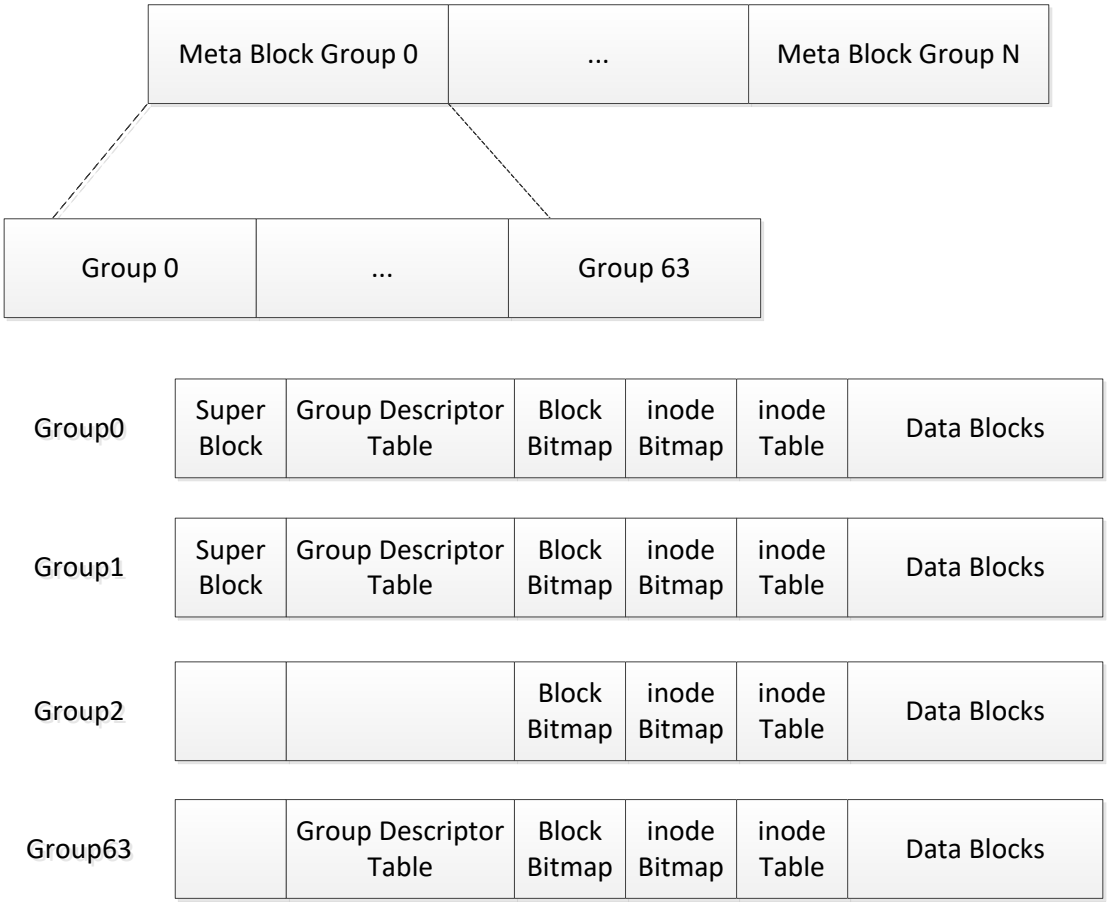

元组块的使用，使得 ext3 和 ext4 的磁盘布局有了变化：
a)：ext3 时超级块后紧跟的是变长的 GDT 块
b)：ext4 时超级块（取决于是否是 3、5、7 的幂）后面跟的是定长（一个数据块大小）的 GDT（且只存储在第一个、第二个和最后一个块组中）。

采用元块组的 ext4 文件系统的大小将不会受块组描述符的影响，并且这种设计对文件系统的扩展非常有利。当需要扩充文件系统的大小，可以在现有数据块之后新添数据块，并将这些数据块也按照元块组的方式进行管理即可。

当然，为了使用这些新增加的空间，在 superblock 结构中需要增加一些字段来记录相关信息（ext4_super_block 结构中增加了一个 s_first_meta_bg 字段用来引用第一个元组块的位置）。

3.2.3 延迟分配

延迟分配是指：通过延迟使得竟可能多的相邻数据块一次被分配，这样既减少系统碎片又提高分配效率从而提高性能。通过一个示意图来说明，如下所示：

ext3 文件系统：

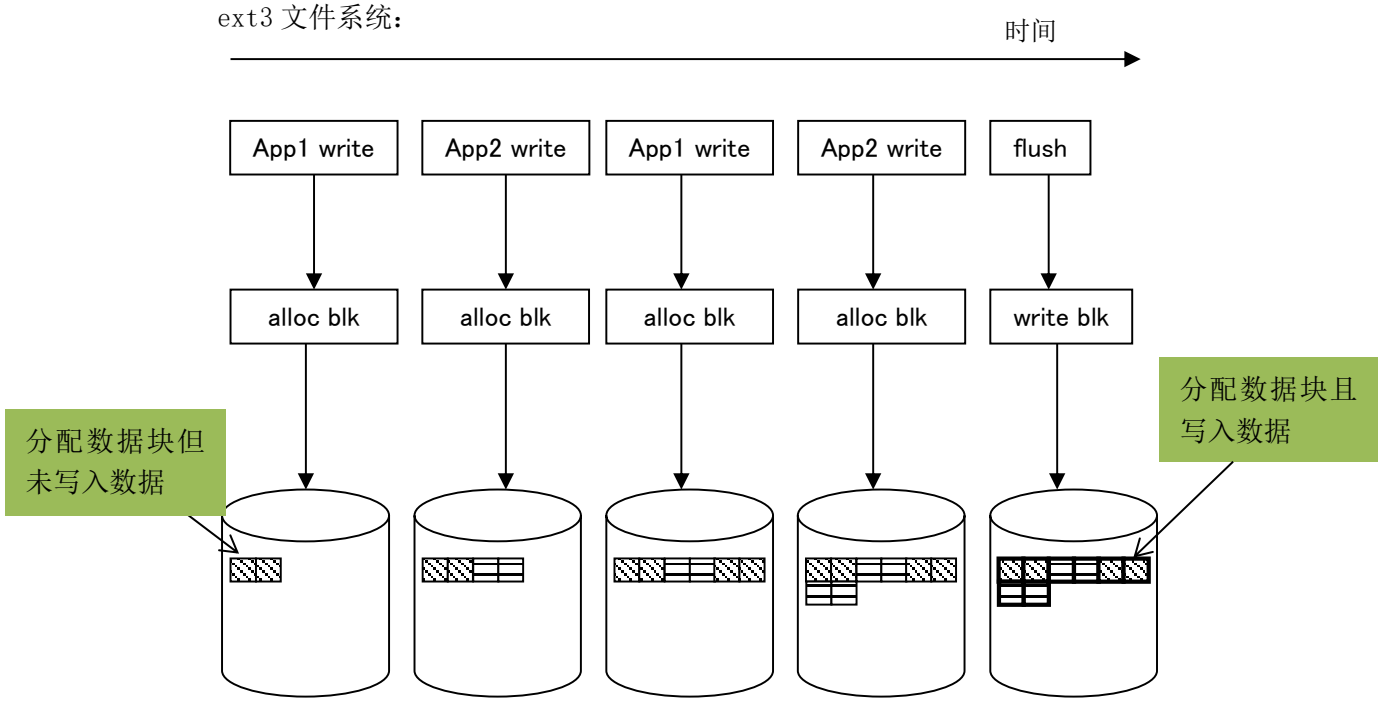

ext4 文件系统：

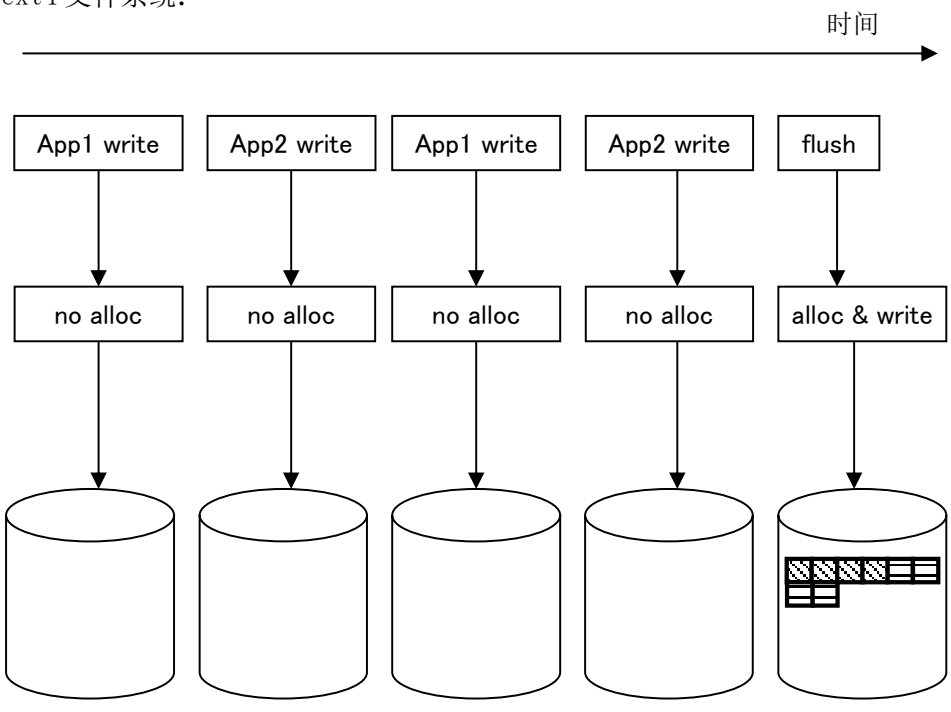

注：在 ext4 文件系统中，延迟分配默认是有效的，使用挂载选项 nodealloc 可以禁用。

3.2.4 更多的子目录

在 ext3 文件系统中，一个目录最多只能包含 32,000 个子目录。在 ext4 文件系统中，取消了这个限制，一个目录可以包含任意多个子目录。

3.2.5 日志 checksum

在 ext3 文件系统中，添加了日志功能。ext4 文件系统则给日志数据添加了 checksum 功能，这样更加提高了系统的安全性和可靠性。

3.2.6 更快的文件系统检查

fsck 命令在检查文件系统时有如下 5 个步骤：
1）Checking inodes、blocks and sizes
2）Checking directory structure
3）Checking directory connectivity
4）Checking reference counts
5）Checking group summary information

在 ext3 文件系统中，fsck 在检查文件系统时会对整个磁盘进行扫描检查。在 ext4 文件系统中，允许 fsck 在检查中跳过磁盘中未使用的部分（主要为步骤一），因此加快了文件系统的检查。通过一个示意图来说明，如下所示：
ext3 文件系统：

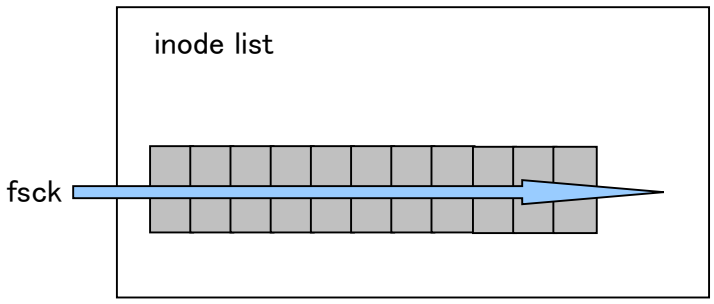

ext4 文件系统：

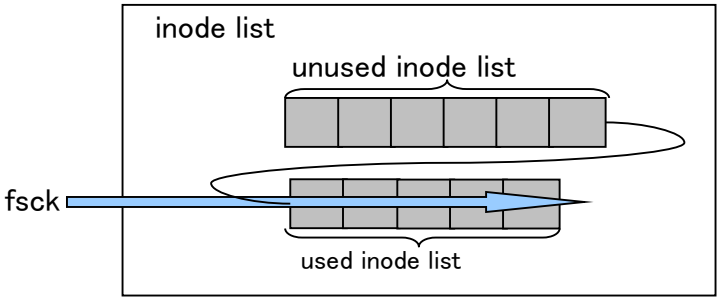

3.2.7 纳秒级时间戳

在 ext3 文件系统中，时间戳的精确只能达到秒级。随着硬件性能的提升，这种精度已经无法区分在同一秒钟创建的文件的时间戳差异。在 ext4 文件系统中，通过扩充索引节点使得时间戳的精度达到了纳秒级的精度，如下所示（引用自 Kernel 的/root/fs/ext4/ext4.h）：

```
524 /*
525  * Structure of an inode on the disk
526  */
527 struct ext4_inode {
528         __le16  i_mode;         /* File mode */
529         __le16  i_uid;          /* Low 16 bits of Owner Uid */
530         __le32  i_size_lo;      /* Size in bytes */
531         __le32  i_atime;        /* Access time */
532         __le32  i_ctime;        /* Inode Change time */
533         __le32  i_mtime;        /* Modification time */
534         __le32  i_dtime;        /* Deletion Time */
535         __le16  i_gid;          /* Low 16 bits of Group Id */
536         __le16  i_links_count;  /* Links count */
537         __le32  i_blocks_lo;    /* Blocks count */
538         __le32  i_flags;        /* File flags */
…
550         __le32  i_block[EXT4_N_BLOCKS];/* Pointers to blocks */
551         __le32  i_generation;   /* File version (for NFS) */
…
578         __le32  i_ctime_extra; /* extra Change time      (nsec << 2|epoch) */
579         __le32  i_mtime_extra; /* extra Modification time(nsec << 2|epoch) */
580         __le32  i_atime_extra; /* extra Access time      (nsec << 2|epoch) */
581         __le32  i_crtime;       /* File Creation time */
582         __le32  i_crtime_extra;/* extra FileCreationtime (nsec << 2|epoch) */
583         __le32  i_version_hi;   /* high 32 bits for 64-bit version */
584 };
```

iflags 标志 i_block_lo 是以扇区大小 512B 还是数据块大小为单位进行计算

此数组的使用方式已改变，不再使用 ext3 那种间接寻址方式，而是用作 extent 树

新增的 5 个字段

3.2.8 extent

在 ext4 文件系统中引入了 extent 的概念来表示文件数据所在的位置。所谓 extent 就是描述保存文件数据使用的连续物理块的一段范围。每个 extent 都是一个 ext4_extent 类型的结构，大小为 12 字节，如下所示（引用自 Kernel 的 root/fs/ext4/ext4_extents.h）：

```
 68 /*
 69  * This is the extent on-disk structure.
 70  * It's used at the bottom of the tree.
 71  */
 72 struct ext4_extent {
 73         __le32  ee_block;       /* first logical block extent covers */
```

```
 74          __le16  ee_len;         /* number of blocks covered by extent */
 75          __le16  ee_start_hi;    /* high 16 bits of physical block */
 76          __le32  ee_start_lo;    /* low 32 bits of physical block */
 77 };
```

每个 ext4_extent 结构可以表示该文件从 ee_block 开始的 ee_len 个数据块，它们在磁盘上的位置是从 ee_start_hi<<32+ee_start_lo 到 ee_start_hi<<32+ee_start_lo+ee_len-1，数据块全部是连续的。

注：ee_len 是一个 16 位的无符号整数，但其最高位被在预分配特性中用来标识这个 extent 是否被初始化过了，因此一个 extent 可以表示 2^15 个连续的数据块，如果采用 4KB 大小的数据块，就相当于 128MB。

如果文件大小超过了一个 ext4_extent 结构能够表示的范围，或者其中有不连续的数据块，就需要使用多个 ext4_extent 结构来表示。为此，还需要两个与 extent 密切相关的结构体来辅助，如下所示（引用自 Kernel 的 root/fs/ext4/ext4_extents.h）：

```
 79 /*
 80  * This is index on-disk structure.
 81  * It's used at all the levels except the bottom.
 82  */
 83 struct ext4_extent_idx {
 84          __le32  ei_block;       /* index covers logical blocks from 'block' */
 85          __le32  ei_leaf_lo;     /* pointer to the physical block of the next *
 86                                   * level. leaf or next index could be there */
 87          __le16  ei_leaf_hi;     /* high 16 bits of physical block */
 88          __u16   ei_unused;
 89 };
 90
 91 /*
 92  * Each block (leaves and indexes), even inode-stored has header
 93  */
 94 struct ext4_extent_header {
 95          __le16  eh_magic;       /* probably will support different formats */
 96          __le16  eh_entries;     /* number of valid entries */
 97          __le16  eh_max;         /* capacity of store in entries */
 98          __le16  eh_depth;       /* has tree real underlying blocks? */
 99          __le32  eh_generation;  /* generation of the tree */
100 };
```

表示在 extent 树中的位置，叶子节点该值为 0，之上每层索引节点依次加 1

ext4 使用一个 extent 树结构来对文件的数据块进行寻址，其中：
a)：结构体 ext4_extent_idx 用来表示下一层的数据块位置且不位于最低层。
b)：结构体 ext4_extent_header 出现在每层的开头，用来表示本层的深度等相关信息。
c)：结构体 ext4_extent 用来表示文件数据块所在的磁盘位置。

用一个示意图来表示，如下所示：

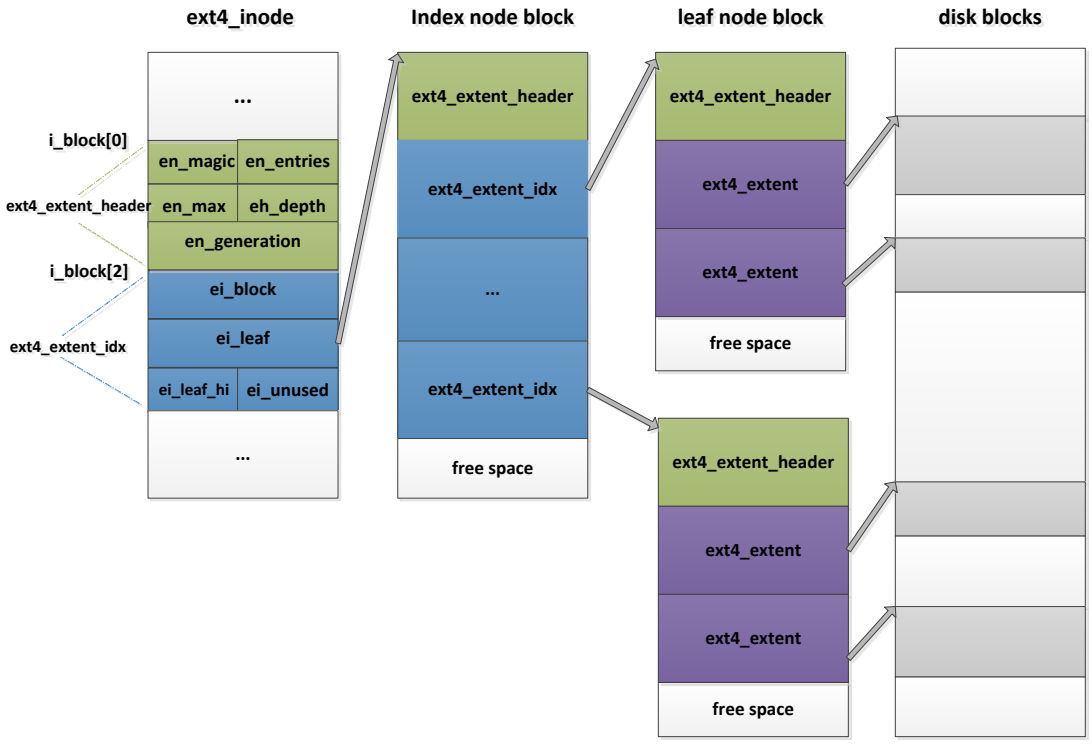

在 extent 树中，节点一共有两类：
1）叶子节点：保存文件数据的磁盘块信息
2）索引节点：保存了下一层节点的位置

ext4 文件系统采用 extent 树结构对文件进行寻址比 ext3 文件系统具有元数据减少、更加灵活等优点，用一个示意图来表示，如下所示：

ext3 文件系统：

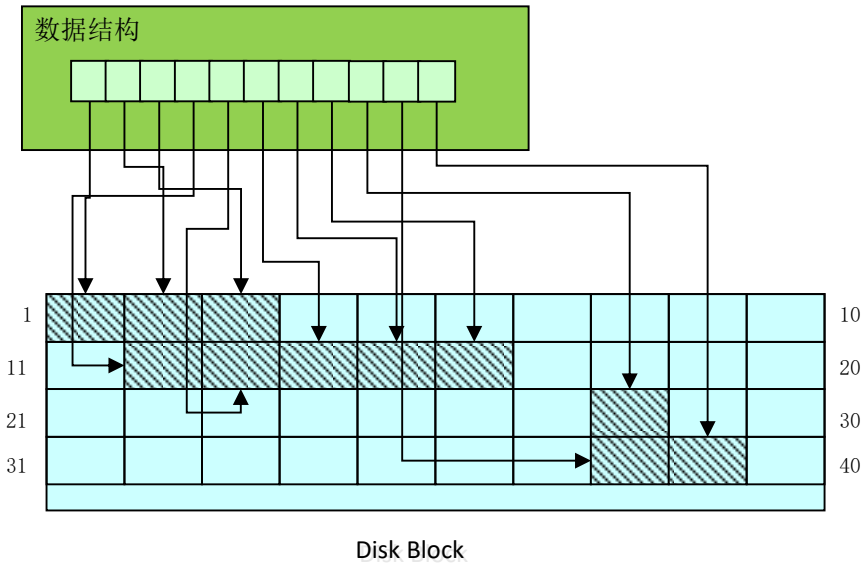

ext4 文件系统：

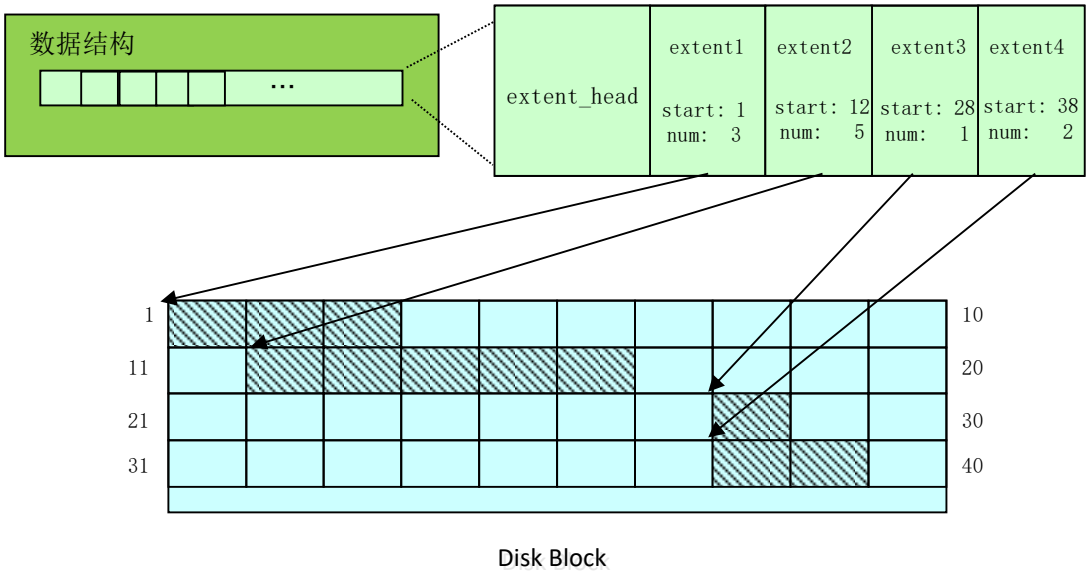

关于使用 extent 树进行文件寻址需要注意以下几点：

1） 尽管索引节点中的 i_block[]字段保持不变，但对这个数组的使用方式已经改变了。其前 3 个元素一定是一个 ext4_extent_header 结构，后续每 3 个元素可能是一个 ext_extent 或 ext4_extent_idx，这取决于所表示文件的大小。

2） i_block[]为一个 60 字节的数组，最多可以保存一个 ext4_extent_header 结构以及 4 个 ext4_extent 结构。对于小文件来说，只需要一次寻址就可以获得保存文件数据块的位置;而超出此限制的文件只能通过遍历 extent 树来获得数据块的位置。对于连续存放的大文件来说，这种方法表示起来很高效，但是对于包含碎片非常多的文件或者稀疏文件来说，这种方法寻址起来要多次读盘。

3） 在 ext3 中 i_blocks 是以扇区（512B）大为单位进行计算的，因此单个文件的最大值为 2^32 * 512B=2TB。而在 ext4 中 i_blocks_lo 可以以数据块大小为单位进行计算，因为单个文件的最大值可以扩充到 16TB（数据块大小为 4KB）。

注：为了避免需要对整个文件系统都需要进行类似转换，还引入了一个 EXT4_HUGE_FILE_FL 标志，i_flags 中不包含这个标志的索引节点的 i_blocks_lo 依然以 512 字节为单位进行计算。当文件所占用的磁盘空间大小增大到不能够用以 512 字节为单位的 i_blocks_lo 来表示时，ext4 自动激活 EXT4_HUGE_FILE_FL 标志，以数据块为单位重新计算 i_blocks_lo 的值。该转换是自动进行的，对用户透明。

3.3 ext4 与 ext3 的关系

ext4 引入了大量新功能，但最重要的是与 ext3 的向后和向前兼容性。为了最大程度的实现兼容性，ext4 尽量保持索引节点、组描述符、目录项等结构不发生大的变化。

ext4 与 ext3 是向前兼容的，这样就可以将 ext4 文件系统挂载为 ext3 文件系统。ext4 与 ext3 是向后兼容的，这样就可以将 ext3 文件系统挂载为 ext4 文件系统。用一个示意图表示，如下所示：

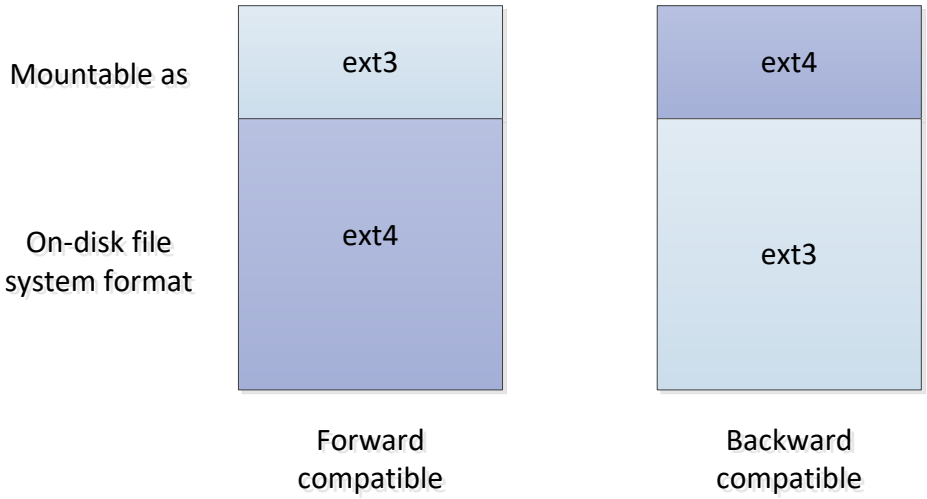

有两点需要注意下：

1) 将 ext3 文件系统挂载为 ext4 时，内核开始使用特定于 ext4 文件系统的功能，如 extent。一旦在这个文件系统中写入文件之后，文件系统所使用的特性中就包含了 extent 特性，这样将导致不能再把文件系统挂载为 ext3 文件系统。

   注：挂载时可以使用-O ^extent 选项来禁用 extent 功能。

2) 尽管把 ext3 文件系统挂载为 ext4 能够实现特定于 ext4 的功能,但挂载本身并不把旧数据结构转换为新的格式。例如，现有文件保持块状方式分配， 而不是使用 extent 进行分配。

3.4 文件恢复

在 ext4 文件系统中删除文件时，不会真正修改存储文件数据所使用的磁盘数据块的内容，而是仅仅删除或修改了相关的元数据信息，使文件数据无法正常索引，从而实现删除文件的母的。因此，在 ext4 文件系统中恢复删除的文件也是完全可能的。

要想恢复已删除的文件需要关心的是文件在磁盘上的存储格式，以目录项的定义来看，如下所示（引用自 Kernel 的/root/fs/ext4/ext4.h）：

```
1297 /*
1298  * Structure of a directory entry
1299  */
1300 #define EXT4_NAME_LEN 255
1301
1302 struct ext4_dir_entry {
1303         __le32  inode;                  /* Inode number */
```

```
1304         __le16  rec_len;                /* Directory entry length */
1305         __le16  name_len;               /* Name length */
1306         char    name[EXT4_NAME_LEN];    /* File name */
1307 };
1308
1309 /*
1310  * The new version of the directory entry.  Since EXT4 structures are
1311  * stored in intel byte order, and the name_len field could never be
1312  * bigger than 255 chars, it's safe to reclaim the extra byte for the
1313  * file_type field.
1314  */
1315 struct ext4_dir_entry_2 {
1316         __le32  inode;                  /* Inode number */
1317         __le16  rec_len;                /* Directory entry length */
1318         __u8    name_len;               /* Name length */
1319         __u8    file_type;
1320         char    name[EXT4_NAME_LEN];    /* File name */
1321 };
```

从上表可以看出，ext4 使用的目录项数据结构 ext4_dir_entry_2 与 ext3 并没有根本的区别，这正是 ext4 和 ext3 互相兼容的基础。

ext4 和 ext3 文件系统具有这么好的兼容性，那么文件的删除操作发生了变化吗？

对比查看一下 ext4 文件系统删除文件前后索引节点信息的变化，如下所示：

```
[root@localhost mountdir]# df -hT
Filesystem    Type    Size  Used Avail Use% Mounted on
/dev/sda2     ext3     15G   14G  519M  97% /
tmpfs        tmpfs    4.0G     0  4.0G   0% /dev/shm
/dev/sda1     ext3    965M  831M   85M  91% /boot
/dev/sde3     ext4    938M   18M  874M   2% /mountdir
[root@localhost mountdir]# debugfs /dev/sde3
debugfs 1.41.12 (17-May-2010)
debugfs:  ls -l
     2   40755 (2)      0      0    4096 11-Feb-2014 13:05 .
     2   40755 (2)      0      0    4096 11-Feb-2014 13:05 ..
    11   40700 (2)      0      0   16384 11-Feb-2014 13:00 lost+found
  7633   40755 (2)      0      0    4096 11-Feb-2014 13:05 dir1
  7634   40755 (2)      0      0    4096 11-Feb-2014 13:05 dir2
    13  100644 (1)      0      0      12 11-Feb-2014 13:05 testfile
    14  100644 (1)      0      0      22 11-Feb-2014 13:05 testfile2
debugfs:  stat <2>
Inode: 2   Type: directory    Mode:  0755   Flags: 0x0
Generation: 0    Version: 0x00000000:00000010
```

这个就是一会将删除的文件

```
User:     0   Group:     0   Size: 4096
File ACL: 0    Directory ACL: 0
Links: 5   Blockcount: 8
Fragment:  Address: 0    Number: 0    Size: 0
 ctime: 0x52f9afa0:dd160f78 -- Tue Feb 11 13:05:36 2014
 atime: 0x52f9afb6:b2e2d658 -- Tue Feb 11 13:05:58 2014
 mtime: 0x52f9afa0:dd160f78 -- Tue Feb 11 13:05:36 2014
crtime: 0x52f9ae65:00000000 -- Tue Feb 11 13:00:21 2014
Size of extra inode fields: 28
BLOCKS:
 (0):69
TOTAL: 1
debugfs:  q
[root@localhost mountdir]# dd if=/dev/sde3 of=/home/renyl/testdir/block.69.orig
bs=4096 count=1 skip=69
1+0 records in
1+0 records out
4096 bytes (4.1 kB) copied, 8.2647e-05 s, 49.6 MB/s
[root@localhost mountdir]# cd /home/renyl/testdir/
[root@localhost testdir]# ./ read_dir_entry block.69.orig 4096
    offset | inode_number | rec_len | name_len | file_type | name
    ============================================================
         0:          2        12         1         2          .
        12:          2        12         2         2          ..
        24:         11        20        10         2          lost+found
        44:       7633        12         4         2          dir1
        56:       7634        12         4         2          dir2
        68:         13        40         8         1          testfile
       108:         12        24        14         1          .testfile2.swp
       132:         14      3988         9         1          testfile2

[root@localhost testdir]# rm -rf /mountdir/testfile
[root@localhost testdir]# umount /mountdir/
[root@localhost testdir]# mount /dev/sde3 /mountdir/
[root@localhost testdir]# debugfs /dev/sde3
debugfs:  lsdel
     Inode  Owner  Mode    Size      Blocks   Time deleted
0 deleted inodes found.
debugfs:  stat <13>
    Inode: 13   Type: regular    Mode:  0644   Flags: 0x80000
    Generation: 3131709158    Version: 0x00000000:00000001
    User:     0   Group:     0   Size: 0
    File ACL: 0    Directory ACL: 0
    Links: 0   Blockcount: 0
```

根目录所对应的数据块号为 169

bs=4096 是因为根目录占一个数据块的大小

这个是之前介绍的读取目录项的程序

重新挂载时确保删除操作同步到磁盘上的数据块中

lsdel 命令已无法显示被删除的文件

文件大小、硬链接数和占用块数都被清空

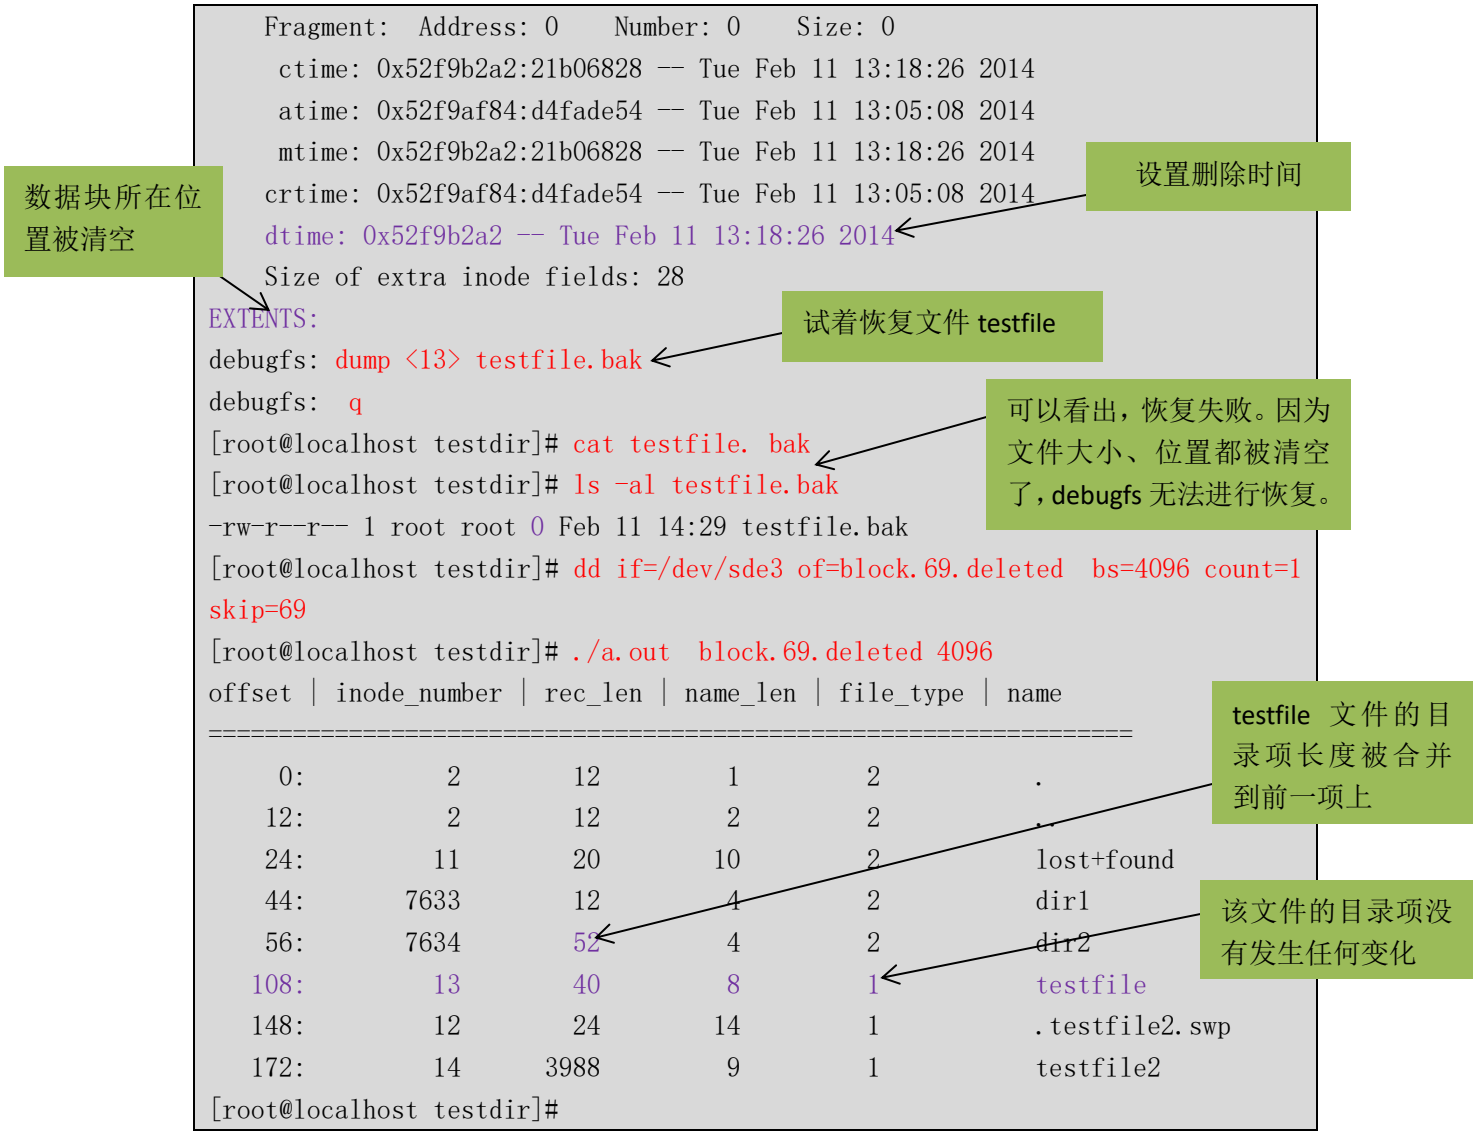

由上图可知：
当目录项被删除时，该目录项的所有相关信息都没有改变，只是将该目录项的空间合并到上一个目录项中，这使得在恢复文件时，文件名可以通过查找目录项中匹配的索引节点号得以正确恢复。

尽管 ext4 文件系统是基于 extent 来管理空间的，但是其恢复原理同 ext3 文件系统一致。在删除文件的同时，除了记录文件名、磁盘设备、索引节点信息之外，把文件大小、数据块位置等重要信息也同时记录下来，这样就可以根据日志文件中的元数据信息完美地恢复文件了。

具体操作可以通过设置环境变量 LD_PRELOAD=***.so 来捕捉一些底层的系统调用（如 unlink、rmdir），修改删除文件的具体操作，把文件大小和数据位置这样的重要信息保存起来，这样就完全可以把删除的文件恢复出来。

4 XFS 文件系统

5 Btrfs 文件系统